

Supervisão Temporal Orientada ao Onset para Inferência Adaptativa Eficiente em Edge AI: Destilação, Gating e Cobertura sob Restrições de Streaming Causal

Ângela Brígida Albarello^{a,*}, Edna Dias Canedo^a, Vinícius P. Gonçalves^a, Leandro A. Villas^b, Rodolfo I. Meneguette^c, Geraldo P. Rocha Filho^{a,d}

^aDepartamento de Ciência da Computação, Universidade de Brasília (UnB), Brasília, DF, 70910-900, Brasil

^bInstituto de Computação, Universidade Estadual de Campinas (UNICAMP), Campinas, SP, 13083-852, Brasil

^cICMC, Universidade de São Paulo (USP), São Carlos, SP, 13566-590, Brasil

^dUniversidade Estadual do Sudoeste da Bahia (UESB), Jequié, BA, 45206-190, Brasil

Abstract

Inferência temporal contínua para detecção de risco do motorista em sistemas embarcados enfrenta um conflito estrutural entre capacidade de modelagem e viabilidade operacional. Arquiteturas compactas o suficiente para execução contínua sob restrições energéticas tendem a operar de forma reativa, respondendo ao risco apenas quando sinais precursores já atingiram intensidade diagnóstica. Modelos com profundidade temporal suficiente para capturar padrões antecipatórios impõem custo incompatível com *streaming* causal em hardware automotivo de borda. A ausência de *benchmarks* com anotação determinística do instante de início do risco agrava esse problema ao tornar métricas de cobertura e latência ambíguas nos datasets naturalísticos disponíveis.

Este trabalho propõe o TERA (*Temporal Evaluation and Risk Assessment*), um *framework* de inferência temporal multimodal para monitoramento de risco do motorista em Edge AI. O TERA integra três componentes. O TERA-Gen sintetiza episódios com início determinístico e progressão de risco calibrada pelos *odds ratios* do SHRP2, fornecendo um *benchmark* reproduzível com 4.160 episódios anotados com precisão de quadro. A AF-TKD (*Adaptive-Focus Temporal Knowledge Distillation*) transfere sensibilidade a padrões precursores de um professor BiLSTM bidirecional para um aluno LSTM causal leve, via ponderação exponencial concentrada nos instantes anteriores ao início do evento, refinando a resposta temporal do modelo sem modificar sua arquitetura de inferência. O mecanismo MHEG (*Motion and Hybrid Entropy Gating*) converte esse refinamento em eficiência computacional, suprimindo seletivamente instantes redundantes com base em variação cinemática e entropia preditiva durante a inferência em *streaming*.

Um estudo de ablação fatorial 2×2 indica que a supressão de quadros sem refinamento temporal degrada sistematicamente a cobertura de detecção, enquanto o *framework* completo alcança F1=0.907, cobertura integral dos episódios críticos (FR=0) e custo de 0.156 ms por instante com 62.1% de supressão, correspondendo a uma redução de 88.5% no custo efetivo. Os resultados sugerem que a antecipação temporal robusta e a supressão eficiente de processamento são compatíveis quando o modelo base é refinado para expressar incerteza estruturada em função da proximidade do risco — implicação direta para o projeto de sistemas de inferência adaptativa em contextos de segurança crítica embarcada.

Keywords: detecção de risco do motorista, Edge AI embarcado, inferência temporal eficiente, destilação de conhecimento orientada ao *onset*, cobertura de detecção temporal, gating adaptativo por entropia, *streaming* causal multimodal, sistemas inteligentes de transporte

1. Introdução

Sistemas de monitoramento embarcado do motorista operam sob uma restrição fundamental: toda inferência deve ser produzida causalmente, a partir do histórico disponível até o instante corrente, em hardware com orçamento energético e de memória incompatível com modelos de grande capacidade [1, 2]. Essa restrição impõe uma tensão estrutural entre capacidade de modelagem e viabilidade de implantação. Arquiteturas compactas

operam de forma reativa, respondendo ao risco quando sinais já atingiram intensidade diagnóstica. Modelos com profundidade temporal suficiente para capturar padrões precursores impõem custo incompatível com *streaming* causal contínuo [3, 4]. Em episódios de emergência rápida, essa limitação se traduz em falhas de detecção sistemáticas nos eventos de maior relevância para a segurança viária.

O SHRP2 *Naturalistic Driving Study* ancora epidemiologicamente esse problema. Comportamentos como discagem manual de celular e desvio prolongado do olhar elevam o risco de colisão em até 12 vezes [5], emergindo ao longo de sequências temporalmente estruturadas de múltiplos sinais. A interação entre estado comportamental e dinâmica veicular constitui um fator de risco independente, não redutível a atributos individuais [5], o que requer modelagem temporal que arquiteturas reativas não

* Autor correspondente.

Email addresses: angela.albarello@aluno.unb.br (Ângela Brígida Albarello), ednacanedo@unb.br (Edna Dias Canedo), vpgvinicius@unb.br (Vinícius P. Gonçalves), lvillas@unicamp.br (Leandro A. Villas), meneguette@icmc.usp.br (Rodolfo I. Meneguette), geraldo.rocha@uesb.edu.br (Geraldo P. Rocha Filho)

proveem.

Dois problemas técnicos agravam essa limitação. O primeiro é mecanístico. Mecanismos de supressão adaptativa baseados em confiança preditiva pressupõem que a incerteza do modelo seja informativa sobre o estado de risco [6, 7]. Em modelos treinados por supervisão convencional, essa condição raramente se verifica: a incerteza tende a permanecer cronicamente baixa, tornando o mecanismo de supressão cego à emergência de risco e comprometendo a cobertura de detecção. O segundo é metodológico. Sem anotação determinística do instante de início nos datasets disponíveis, métricas de latência e cobertura permanecem ambíguas, e episódios não detectados desaparecem da média sem penalidade explícita [8, 9, 10].

A hipótese central deste trabalho é que esses problemas têm origem comum na ausência de refinamento temporal orientado ao instante de início do risco. Quando a resposta temporal do modelo é ajustada para que a incerteza preditiva reflita a proximidade do evento, a supressão seletiva torna-se compatível com cobertura robusta. Essa propriedade não emerge de treinamento convencional; ela requer um protocolo que tome o *onset* como ancoragem explícita para a transferência de sensibilidade precursora. Verificar essa hipótese exige adicionalmente um *benchmark* com anotação determinística e métricas que penalizem episódios não detectados.

Para endereçar esses problemas, este trabalho propõe o TERA (*Temporal Evaluation and Risk Assessment*), um *framework* de inferência temporal multimodal para detecção de risco do motorista em Edge AI. O TERA integra três componentes. O TERA-Gen é um gerador de cenários sintéticos com *onset* determinístico e progressão de risco ancorada nos *odds ratios* do SHRP2, fornecendo um *benchmark* reproduzível com 4.160 episódios. A AF-TKD (*Adaptive-Focus Temporal Knowledge Distillation*) transfere sensibilidade a padrões precursores de um professor BiLSTM bidirecional para um aluno LSTM causal leve, via ponderação exponencial concentrada nos instantes anteriores ao *onset*. O MHEG (*Motion and Hybrid Entropy Gating*) converte o refinamento resultante em eficiência computacional, suprimindo instantes redundantes durante a inferência em *streaming*.

A organização do artigo segue a estrutura do *framework*. A Seção 2 revisa a literatura de monitoramento de motoristas, fusão multimodal e inferência eficiente em Edge AI. A Seção 3 descreve os objetivos e a arquitetura do *framework*. A subseção 3.1 apresenta o TERA-Gen. As subseções 3.2 e 3.3 detalham a AF-TKD e o MHEG. A Seção 4 reporta a avaliação experimental. A Seção 5 discute resultados e limitações. A Seção 6 apresenta as conclusões.

2. Trabalhos Relacionados

2.1. Monitoramento de Motoristas e Avaliação Temporal

Sistemas baseados em câmera frontal e sensores fisiológicos estabeleceram a viabilidade da detecção automática de distração e sonolência em ambiente naturalístico. O DMD [10] oferece anotações densas para sete classes de comportamento de risco, enquanto o DADA [8] complementa com dados de fixação de olhar em 54 cenários de pré-colisão.

A revisão de Bouhsissin et al. [3] documenta a transição de classificadores por quadro isolado para arquiteturas recorrentes e baseadas em atenção, com ganhos consistentes de modelos temporais sobre abordagens estáticas. Esse resultado é coerente com a evidência do SHRP2, que associou comportamentos de distração a aumentos de risco de até 12 vezes [5] ao longo de sequências de múltiplos segundos. Tanto os datasets disponíveis quanto os protocolos da revisão adotam métricas de desempenho agregado sobre cliques completos, sem distinguir se a detecção ocorreu antes ou após o estabelecimento pleno do risco. A avaliação orientada ao instante de início, necessária para medir antecipação efetiva, permanece ausente nessa literatura.

2.2. Fusão Multimodal e Modelagem Temporal de Risco

O comportamento do motorista raramente se manifesta em uma única modalidade. Michelaraki et al. [9] indicam que a combinação de câmera e telemetria veicular melhora a detecção de sonolência em relação a abordagens unimodais, resultado consistente com o princípio de que modalidades complementares reduzem falsos negativos em condições de oclusão.

A escolha de estratégia de fusão tem implicações computacionais diretas. Fusão tardia oferece flexibilidade arquitetural mas multiplica o custo de inferência. Fusão precoce por concatenação de atributos apresenta desempenho competitivo com menor overhead e é preferida em Edge AI [1, 2]. Arquiteturas de atenção cruzada ampliam a capacidade de modelar dependências intermodais, porém com complexidade incompatível com inferência causal contínua em hardware restrito.

2.3. Inferência em Borda e Restrições de Plataforma Embarcada

Plataformas como Jetson Nano, Qualcomm SA8155P e variantes de Raspberry Pi impõem memória limitada, largura de banda reduzida e orçamento energético restrito [1]. Hariharan et al. [2] indicam que quantização de 8 bits permite implantar detectores de distração com aceleração significativa sem degradação perceptível de acurácia, estabelecendo um protocolo de viabilidade baseado em FPS e latência por quadro em modo *batch*=1.

A escolha de arquitetura recorrente é condicionada por restrições causais. Redes LSTM e GRU apresentam custo assintótico por passo inferior ao de Transformers com atenção completa, sendo mais adequadas para *streaming* contínuo sob restrições energéticas [6]. Transformers com atenção global pressupõem acesso ao contexto futuro, incompatível com inferência causal online. O desempenho em *streaming* causal sob restrições embarcadas constitui, portanto, uma dimensão de avaliação independente da acurácia em modo *batch*.

2.4. Modelagem Temporal Profunda e Destilação de Conhecimento

Modelos como LSTR [4], TeSTra [11] e MAT [12] avançaram o desempenho em benchmarks de reconhecimento de ação online. Sua implantação direta em plataformas embarcadas é limitada pelo custo de memória e processamento.

A destilação de conhecimento [13] permite transferir capacidade de um professor profundo para um aluno compacto sem elevar o custo de inferência. No domínio temporal, o TempDistiller [14] propõe transferência de memória via reconstrução mascarada, enquanto Bajestani e Yang [15] utilizam seleção de *keyframes* para guiar o aluno ao longo da sequência. Ambas as abordagens tratam a sequência como um todo homogêneo, sem ancorar a transferência no instante de início do evento — limitação relevante em sistemas de monitoramento do motorista, onde os instantes imediatamente anteriores ao *onset* concentram o conteúdo informativo mais relevante para antecipação de risco.

2.5. Supressão Adaptativa de Quadros em Contextos de Segurança

SkipRNN [6], AdaFrame [7], ACT [16] e LiteEval [17] indicaram que mecanismos de *gating* reduzem custo computacional em 40% a 70% sem degradação perceptível em tarefas de reconhecimento de ação. O SkipRNN opera em modo causal; os demais operam predominantemente offline.

Esses mecanismos compartilham a premissa de que baixa incerteza preditiva indica condições estáveis. Em reconhecimento de atividade cotidiana, essa heurística apresenta bom desempenho. Em monitoramento veicular, a transição entre condução normal e início de um episódio de distração pode ocorrer de forma gradual, com incerteza baixa nos quadros imediatamente anteriores ao *onset*. A validade dessa premissa sobre eventos críticos não é verificada empiricamente nos trabalhos de inferência adaptativa [6, 7], limitando sua aplicabilidade em contextos de segurança veicular sem validação específica.

2.6. Lacunas e Posicionamento

A revisão evidencia quatro limitações que se reforçam mutuamente. A pesquisa em monitoramento do motorista avançou em modelagem temporal, mas persiste em avaliação por desempenho agregado, sem métricas orientadas ao *onset*. Trabalhos de fusão multimodal melhoram robustez de detecção, porém elevam o custo sem estratégias compatíveis com execução causal contínua em borda. Métodos de destilação temporal produzem modelos compactos, mas não tratam o início do evento como ancoragem para transferência de sensibilidade precursora. Mecanismos de supressão reduzem custo de forma expressiva, mas sua premissa de redundância temporal não foi verificada sobre episódios críticos de emergência rápida. A essas limitações soma-se a ausência de *benchmarks* com anotação determinística de *onset* [8, 9].

Nenhum trabalho existente trata conjuntamente geração de cenários com *onset* determinístico, refinamento temporal orientado ao início do evento, avaliação explícita de cobertura e ablação de eficiência computacional em um framework para monitoramento de motoristas em borda. A Tabela 1 sintetiza esse posicionamento em cinco dimensões.

3. Framework de Inferência Multimodal Causal e Objetivos de Desempenho

Todo sistema de detecção de risco embarcado processa sinais estritamente na ordem de chegada, sem acesso a observações

Table 1: Posicionamento em relação à literatura. **Onset**: cenários com *onset* determinístico. **Multimod.**: fusão de múltiplas modalidades. **Causal**: inferência online sem acesso ao contexto futuro. **Cobert.**: avaliação explícita de cobertura de detecção. **Efic.**: ablação de eficiência computacional. $\circ$: parcialmente satisfeito.

Trabalho	Onset	Multimod.	Causal	Cobert.	Efic.
<i>Monitoramento e comportamento do motorista</i>					
Ortega et al. (DMD) [10]	×	✓	×	×	×
Bouhsissin et al. [3]	×	✓	×	×	×
Michelaraki et al. [9]	×	✓	×	×	×
<i>Edge AI e inferência eficiente</i>					
Hariharan et al. [2]	×	×	$\circ$	×	✓
Campos et al. (SkipRNN) [6]	×	×	✓	×	✓
Wu et al. (AdaFrame) [7]	×	×	×	×	✓
<i>Modelagem temporal e destilação</i>					
Zhao & Krähenbühl [11]	×	×	✓	×	×
Zheng et al. [14]	×	×	×	×	$\circ^{\dagger}$
Bajestani & Yang [15]	×	×	×	×	×
Este trabalho	✓	✓	✓	✓	✓

† Ablação parcial de eficiência sem métricas de cobertura.

futuras. Essa restrição causal define a arquitetura do framework desde seus fundamentos. O pipeline ingere um fluxo contínuo $\mathbf{x} = (x_1, x_2, \dots)$, em que cada vetor $x_t \in \mathbb{R}^D$ codifica observações simultâneas nos domínios visual, cinemático, contextual e acústico. A saída y_t é função exclusiva do histórico $\{x_1, \dots, x_t\}$, determinando a viabilidade de implantação e separando estruturalmente o modelo de inferência dos modelos bidirecionais empregados como professores durante o treinamento.

O núcleo preditivo do dispositivo é uma LSTM unidirecional de duas camadas, com custo assintótico $O(4(DH+H^2))$ por passo, equilibrando capacidade representacional e viabilidade de execução contínua em hardware embarcado de baixo consumo. Durante o treinamento *offline*, um professor BiLSTM supervisiona esse modelo via AF-TKD, transferindo sensibilidade a padrões precursores. Concluído o treinamento, o professor é descartado; o dispositivo carrega apenas os pesos do aluno e os limiares de *gating* calibrados.

A avaliação organiza-se em três objetivos complementares (Tabela 2). A qualidade preditiva é mensurada por F1, Precisão e Revocação. A eficiência computacional é capturada pelo custo médio por instante (ms/q), taxa de supressão (%Sup) e *throughput* efetivo (FPS). A cobertura de detecção verifica se eventos críticos são identificados dentro de uma janela que permita intervenção útil, expressa pela taxa de falhas (FR) e pelo atraso efetivo de detecção (TTD_{ef}).

A formulação de TTD_{ef} corrige uma distorção presente na literatura: quando apenas episódios bem-sucedidos entram na média de latência, eventos não detectados desaparecem do cálculo, produzindo desempenho artificialmente otimista. A métrica incorpora uma penalidade explícita, seguindo o princípio das curvas AMOC [18]:

$$TTD_{ef} = TTD_{det} + FR \times T_{ep}, \quad T_{ep} = 10,0 \text{ s.} \quad (1)$$

Um sistema com $FR=0,067$ e TTD bruto de 0,008 s apresenta TTD_{ef} de 0,674 s, pois 6,7% dos eventos críticos não geram alerta.

Os objetivos de eficiência e cobertura mantêm uma relação de dependência não trivial. Mecanismos de supressão baseados em incerteza preditiva pressupõem que baixa incerteza corresponda a condições estáveis. Em modelos treinados por su-

Table 2: Objetivos de desempenho do *framework*.

Objetivo	Métricas	Meta	Significado
Deteção	F1, Prec., Rev.	maximizar	Qualidade preditiva sobre fluxo multimodal
Eficiência	ms/q, %Sup, FPS	minimizar/maximizar	Viabilidade de execução contínua em Edge AI
Cobertura	FR, TTD _{ef}	minimizar	Proporção de eventos críticos detectados em tempo útil

ECE reportada como indicador auxiliar de qualidade de resposta temporal.

pervisão convencional, a incerteza tende a permanecer baixa mesmo durante a emergência de risco, tornando o sinal pouco discriminante. A supressão tende a concentrar-se justamente durante transições críticas, quando a atualização do estado interno é mais relevante para a cobertura. O refinamento introduzido pelo AF-TKD modifica essa dinâmica ao ajustar a resposta temporal do modelo durante o treinamento, tornando a incerteza informativa sobre a proximidade do risco. Essa dependência entre refinamento temporal e supressão eficiente fundamenta a arquitetura sintetizada na Figura 1.

As subseções seguintes detalham os três componentes. O TERA-Gen estabelece uma infraestrutura de avaliação com início determinístico. O protocolo AF-TKD explora essa anotação para transferir sensibilidade precursora de um professor bidirecional para um aluno causal leve. O mecanismo MHEG utiliza a incerteza resultante como sinal de controle para supressão seletiva durante a inferência em *streaming*.

3.1. TERA-Gen: Benchmark de Cenários com Início Determinístico

Medir o atraso de detecção com precisão de instante requer saber com exatidão quando o comportamento de risco teve início. Nas bases naturalísticas disponíveis — SHRP2 [5], DADA [8] e DMD [10] — esse instante é determinado por anotação humana retrospectiva, sujeita a variabilidade típica de $\pm k$ posições. A 9,6 fps, $k=3$ corresponde a $\approx 0,31$ s de incerteza, suficiente para ocultar diferenças reais entre sistemas. Episódios não detectados agravam o problema ao serem excluídos da média de latência sem penalidade explícita.

O TERA-Gen aborda essas limitações como gerador de cenários com início determinístico e progressão de risco inteiramente parametrizada, convertendo a avaliação em um *benchmark* reproduzível. O sistema representa a interação temporal entre comportamento humano, dinâmica veicular, contexto operacional e sinais acústicos em 31 atributos que funcionam como proxies multimodais de fatores de risco documentados em estudos naturalísticos.

Estrutura dos episódios. O vetor $x_t \in \mathbb{R}^{31}$ cobre quatro domínios. O domínio visual-comportamental codifica o estado do operador em sete classes (*one-hot*): condução normal, uso de celular, ajuste de rádio, alimentação, pegar objeto, *grooming* e conversa com passageiro, representando combinações de distração visual, manual e cognitiva do SHRP2 [5]. Inclui também indicadores de cinto de segurança, desvio lateral de faixa e *eye_gaze_off_road* calibrado pelo *odds ratio* 7,1 do SHRP2.

Table 3: Comportamentos de risco calibrados pelo SHRP2 [5].

Comportamento	Categoria	OR	risk_target
Condução normal	Normal	1,0	0,050
Conversa via viva-voz	Atenção	1,3	0,074
Fadiga leve / sonolência	Alerta	4,0	0,290
Pegar objeto em movimento	Crítico	9,1	0,698
Discagem manual de celular	Crítico	12,2	0,946

O domínio cinemático registra velocidade normalizada, aceleração e frenagem bruscas, sinais giroscópicos e a interação entre uso de celular e velocidade corrente, distinguindo cenários de risco qualitativamente distintos (veículo parado, tráfego urbano, rodovia de alta velocidade).

Domínios de contexto (tipo de via, precipitação, regime noturno, densidade de tráfego) e acústico (sirene, buzina, toque de celular, entre outros) complementam o vetor, incorporados como amplificações aditivas ao alvo de risco do episódio. Dois atributos modelam a confiança dos detectores embarcados, representando degradação perceptual em condições de oclusão.

Calibração epidemiológica. Os alvos de risco são ancorados nos *odds ratios* do SHRP2, transferidos ao domínio contínuo $[0,05, 1,00]$ pelo mapeamento:

$$risk_target \approx 0,05 + \frac{OR - 1}{12,5}, \quad (2)$$

preservando relações ordinais entre comportamentos (Tabela 3). O rótulo de episódio pondera trajetória temporal e intensidade dos picos:

$$y_{ep} = 0,7 \text{ mean}(y_{frame}) + 0,3 p_{95}(y_{frame}), \quad (3)$$

refletindo que picos breves mas intensos contribuem desproporcionalmente para a severidade global do episódio.

Regimes de emergência. O TERA-Gen contempla dois padrões temporais complementares. Episódios **progressivos** (60% dos críticos) simulam distração sustentada ou fadiga acumulada, com fase latente de 8 a 20 instantes e janela de antecipação de $\approx 1,4$ s. Episódios **abruptos** (40% restantes) modelam perturbações de rampa rápida com janela de antecipação inferior a 0,6 s, constituindo o regime de maior dificuldade para sistemas em tempo real. Em ambos os casos, t_0 é determinístico, tornando o atraso de detecção e a taxa de falhas mensuráveis com precisão de quadro.

Taxonomia de receitas e desenho binário de supervisão. Os episódios são gerados a partir de *receitas* — templates que especificam sequência de comportamentos, velocidade, contexto e alvo de risco. O conjunto de treino compreende 13 receitas: três de condução normal (N01–N03, variando velocidade e contexto viário) e dez de situação crítica (C01–C10, cobrindo as principais categorias de distração documentadas no SHRP2: celular, fadiga, *grooming*, pegar objeto, alimentação e combinações). Essa escolha é deliberada: o conjunto de treino é **estritamente binário** — Normal ou Crítico — espelhando a estrutura dos datasets naturalísticos de referência (SHRP2, DMD), nos quais os rótulos




Figure 1: **Arquitetura do framework proposto**, com separação explícita entre treinamento *offline* e inferência embarcada *online*. Na fase *offline*: (1) TERA-Gen sintetiza episódios com início determinístico; (2) o professor BiLSTM é treinado com acesso bidirecional; (3) AF-TKD transfere sensibilidade precursora ao aluno LSTM causal; (4) pesos e limiares são exportados ao dispositivo. Na fase *online*: (1) sensores coletam sinais em tempo real; (2) MHEG decide por supressão ou atualização a cada instante; (3) o aluno LSTM infere nos instantes selecionados; (4) a probabilidade contínua é mapeada em nível de alerta ℓ_t . Professor, AF-TKD e TERA-Gen não residem no dispositivo.

Table 4: Taxonomia de receitas do TERA-Gen.

Conjunto	Nível	Receitas	Uso
Treino	Normal	N01–N03	Treino / Val / Teste
	Crítico	C01–C10	Treino / Val / Teste
Borderline	Atenção	A01–A03	Apenas avaliação
	Alerta	L01–L03	Apenas avaliação

disponíveis correspondem a eventos de crash/near-crash, sem anotação de severidade intermediária. O objetivo científico é verificar se a supervisão binária com calibração temporal onset-aware é suficiente para que o modelo produza probabilidades contínuas com estrutura semântica coerente como subproduto — hipótese testada na Seção 4.6.

Receitas borderline para avaliação de generalização. Para testar a generalização a severidades não supervisionadas, definem-se seis receitas adicionais exclusivamente para avaliação (Tabela 4): três de **Atenção** (A01–A03) — condução sem distração comportamental mas com contexto adverso sustentado: chuva intensa, período noturno e congestionamento — e três de **Alerta** (L01–L03) — comportamentos de distração fraca a velocidade reduzida: conversa prolongada em rodovia, ajuste de rádio em velocidade moderada e alimentação em trecho urbano lento. Nenhuma dessas receitas é apresentada ao modelo durante o treino ou a validação. A hierarquia esperada é Normal < Atenção < Alerta < Crítico; os resultados e sua interpretação são discutidos na Seção 4.6.

Composição do conjunto de dados. O conjunto reúne 4.160 episódios em quatro sementes (42–45), com 1.040 por semente,

particionados em 70/15/15 (treino-validação-teste) com estratificação por receita. Cada episódio contém $T=96$ instantes a $\approx 9,6$ fps, com $D=31$ atributos e anotação de início com precisão de quadro.

3.2. AF-TKD: Refinamento Temporal por Destilação de Conhecimento

A arquitetura causal impõe ao modelo implantado uma limitação concreta. Processando sinais na ordem de chegada, a LSTM unidirecional não recorre ao contexto futuro para reconhecer padrões que só se tornam identificáveis retrospectivamente, respondendo ao risco quando os sinais já atingiram intensidade diagnóstica. Em episódios abruptos, com janela de antecipação inferior a 0,6 s, esse comportamento compromete a cobertura.

A AF-TKD corrige esse comportamento durante o treinamento, sem alterar a arquitetura de inferência. O protocolo é assimétrico por construção. Um professor BiLSTM, treinado com acesso bidirecional à sequência completa, constrói representações retrospectivamente informadas dos precursores e as transfere ao aluno causal via destilação. Essa assimetria é explorada exclusivamente na fase *offline*; no dispositivo, o modelo opera com os mesmos pesos LSTM, com resposta temporal ajustada pelo protocolo.

Função de perda com foco no instante de início. A perda AF-TKD combina dois termos de supervisão:

$$\mathcal{L}_{\text{hard}} = \text{BCE}(y_{\text{ep}}, \hat{p}_s), \quad (4)$$

$$\mathcal{L}_{\text{soft}} = T^2 \cdot \text{KL}\left(\sigma\left(\frac{z_p}{T}\right) \parallel \sigma\left(\frac{z_s}{T}\right)\right), \quad (5)$$

$$\mathcal{L}_{\text{AF-TKD}} = (1 - \lambda_{\text{KD}}) \mathcal{L}_{\text{hard}} + \lambda_{\text{KD}} \mathcal{L}_{\text{soft}}, \quad (6)$$

com temperatura $T=2,0$ e logits z_p, z_s do professor e aluno. O termo *hard* ancora a otimização nos rótulos reais; o *soft* induz o aluno a mimetizar as estimativas do professor nos instantes de maior ambiguidade, onde a informação sobre precursores é mais relevante.

A concentração do gradiente sobre esses instantes é obtida pela ponderação exponencial:

$$w(t) = \exp(-\alpha \cdot t), \quad \alpha = 0,15, \quad (7)$$

em que t representa a distância ao instante de início. A perda efetiva por posição torna-se $\tilde{\mathcal{L}}_{\text{AF-TKD}}(t) = w(t) \cdot \mathcal{L}_{\text{AF-TKD}}(t)$, normalizada pelo comprimento da janela. Esse esquema é ativo apenas em episódios críticos com início anotado, evidenciando a dependência direta entre AF-TKD e a infraestrutura do TERA-Gen.

O refinamento ajusta a resposta temporal do aluno de modo que a incerteza preditiva reflita a proximidade do risco — propriedade que o MHEG, descrito a seguir, converte em eficiência computacional em tempo de execução.

Protocolo de treinamento em três fases. A introdução gradual do sinal do professor previne instabilidade. Nas primeiras 10 épocas (*warm-up*), com $\lambda_{\text{KD}}=0$, o aluno é otimizado apenas com rótulos reais. As 17 épocas seguintes (*ramp-up*) elevam λ_{KD} linearmente ao valor de regime. As 53 épocas finais mantêm λ_{KD} fixo.

3.3. MHEG: Gating Adaptativo por Movimento e Entropia

Em tempo de execução, a incerteza preditiva ajustada pelo AF-TKD opera como sinal de controle para supressão seletiva. Quando o modelo está confiante na ausência de risco e os sinais não apresentam variação cinemática relevante, o estado oculto pode ser propagado sem atualização, poupando o custo completo da passagem *forward*. Essa premissa requer que o refinamento temporal tenha sido aplicado; sem ele, a incerteza de modelos convencionalmente treinados tende a permanecer baixa independentemente do estado de risco, como indica o controle negativo Baseline+Gating na Seção 4.

O mecanismo opera como camada de controle posicionada entre o sensor e a LSTM, tomando decisões a cada instante sem modificar os pesos do modelo, tornando-o transparente ao treinamento e removível para ablação.

Critério de ativação. A variação cinemática $|\Delta x_t|$ detecta mudanças abruptas de estado sensorial que devem ser processadas independentemente da incerteza corrente. A entropia preditiva do instante anterior,

$$H(p_{t-1}) = -p_{t-1} \log_2 p_{t-1} - (1 - p_{t-1}) \log_2 (1 - p_{t-1}), \quad (8)$$

sinaliza incerteza sobre a condição de segurança, assumindo valores elevados quando a supressão seria mais custosa para a cobertura. O núcleo LSTM é ativado quando

$$(|\Delta x_t| \geq \tau_\Delta) \vee (H(p_{t-1}) \geq \tau_H); \quad (9)$$

caso contrário, saída e estado anteriores são propagados sem custo. Os dois critérios fornecem cobertura complementar: a condição cinemática responde a episódios abruptos; a condição entrópica captura emergência progressiva de risco sem perturbação sensorial imediata.

Calibração dos limiares. Com os pesos do aluno congelados, a calibração percorre uma grade de 16 combinações (τ_Δ, τ_H) por semente, maximizando a taxa de supressão sob restrições estritas: $\text{FR}_{\text{val}} \leq 0,05$ e degradação máxima de 20% no TTD_{ef} . Em média, 4 a 5 das 16 combinações satisfazem ambas, com supressão entre 28% e 62%. A estabilidade da região calibrada é verificada por perturbações de $\pm 10\%$ nos limiares selecionados.

3.4. Saída de Risco Graduada e Ciclo de Inferência

A probabilidade p_t é convertida em quatro níveis de severidade com limiares calibrados empiricamente sobre a distribuição de saída do modelo treinado (Seção 4.6), preservando a ordenação ordinal da escala epidemiológica do SHRP2 [5]:

$$\ell_t = \begin{cases} 0 \text{ (Normal)} & p_t < 0,15 \\ 1 \text{ (Atenção)} & 0,15 \leq p_t < 0,38 \\ 2 \text{ (Alerta)} & 0,38 \leq p_t < 0,50 \\ 3 \text{ (Crítico)} & p_t \geq 0,50 \end{cases} \quad (10)$$

permitindo que sistemas ADAS calibrem a intensidade da intervenção ao grau de risco estimado.

O Algoritmo 1 formaliza o ciclo completo. O *gating* resolve em $\mathcal{O}(1)$; quando não ativa o modelo, o estado anterior é propagado sem custo. O nível $\ell_t \in \{0, 1, 2, 3\}$ é emitido a cada instante, incluindo $\ell_t=0$ (Normal), garantindo que o sistema ADAS receba confirmação contínua de estado mesmo na ausência de risco. Todo o ciclo é determinístico e livre de gradiente no dispositivo.

4. Avaliação Experimental

4.1. Protocolo Experimental

Os experimentos cobrem 4.160 episódios em quatro sementes (42–45), particionados em 70/15/15 com estratificação por receita. Resultados são reportados como média $\pm$ desvio padrão entre sementes. Comparações são verificadas pelo teste de Wilcoxon pareado ($n=4$) com delta de Cliff [?]; intervalos de confiança de 95% por *bootstrap* estratificado.

A detecção estável exige três instantes consecutivos acima do limiar:

$$\text{TTD}_{\text{det}} = (t_{\text{det}} - t_0) \cdot \Delta t, \quad \Delta t = 10/T, \quad (11)$$

$$t_{\text{det}} = \min\{t \geq t_0 \mid p_t, p_{t+1}, p_{t+2} \geq \theta_{\text{TTD}}\}.$$

Episódios sem t_{det} contribuem com penalidade de $T_{\text{ep}}=10$ s ao TTD_{ef} . O custo por instante (ms/q) é medido em modo *batch*=1 numa GPU NVIDIA RTX 3050 Ti (PyTorch 2.0), com sincronização explícita após aquecimento de 100 passos.

Algorithm 1 Ciclo de inferência eficiente em tempo de execução

Require: Pesos θ_{LSTM} ; limiares τ_Δ , τ_H , $\theta_1=0,15$, $\theta_2=0,38$, $\theta_3=0,50$; $h_0=0$; $y_0=0$

Ensure: Nível $\ell_t \in \{0, 1, 2, 3\}$ emitido a cada instante t

```

1: for cada quadro  $x_t$  do
2:    $\Delta x_t \leftarrow \max_{k \in \mathcal{K}} |x_t^{(k)} - x_{t-1}^{(k)}|$      $\mathcal{K}$ : índices cinemáticos
3:    $H_t \leftarrow H(y_{t-1})$                                 Eq. 8
4:   if ( $\Delta x_t \geq \tau_\Delta$ ) or ( $H_t \geq \tau_H$ ) then
5:      $(y_t, h_t) \leftarrow \text{LSTM}(x_t, h_{t-1}; \theta_{\text{LSTM}})$  custo  $O(4(DH+H^2))$ 
6:   else
7:      $y_t \leftarrow y_{t-1}$ ;  $h_t \leftarrow h_{t-1}$                 custo  $\approx 0$ 
8:   end if
9:    $\ell_t \leftarrow \mathbf{1}[y_t \geq \theta_3] \cdot 3 + \mathbf{1}[\theta_2 \leq y_t < \theta_3] \cdot 2 + \mathbf{1}[\theta_1 \leq y_t < \theta_2] \cdot 1$ 

10: Emita  $\ell_t$                                 sempre emitido, inclusive  $\ell_t=0$ 
11: end for

```

Inferência causal, sem gradiente no dispositivo. ℓ_t emitido a cada instante independentemente da ativação da LSTM; $\ell_t=0$ confirma estado Normal ao sistema ADAS.




Figure 2: Evidência temporal frame-a-frame (semente 42). Colunas: Baseline (esq.) e AF-TKD+Gating (dir.). Linhas: episódio progressivo (sup.) e abrupto (inf.). Curva sólida: $p(t)$; curva tracejada: $H(t)$. Linha vertical: t_0 . Marcador ∇ : t_{det} . Regiões cinzas: instantes suprimidos. No AF-TKD+Gating, as supressões concentram-se nos períodos de $H(t)$ baixa (estado estável), confirmando seletividade.

4.2. Evidência Temporal Frame-a-Frame

A hipótese central é que a supervisão *onset-aware* do AF-TKD ajusta a resposta temporal do aluno de modo que a incerteza preditiva se torna estruturada o suficiente para viabilizar supressão seletiva segura. A evidência experimental é organizada em quatro elos, cada um isolando um passo: AF-TKD $\rightarrow$ resposta temporal $\rightarrow$ incerteza estruturada $\rightarrow$ gating compatível com cobertura $\rightarrow$ inferência eficiente.

A Figura 2 apresenta a evidência frame-a-frame. No Baseline, $p(t)$ permanece abaixo do limiar até após t_0 e $H(t)$ mantém-se uniformemente baixa — o modelo expressa alta confiança mesmo em estados de risco emergente. No AF-TKD, $p(t)$ cresce na janela pré-onset em episódios progressivos e $H(t)$ eleva-se na vizinhança de t_0 , tornando-se estruturada: alta nos instantes de maior incerteza relevante, baixa nos períodos estáveis.

Table 5: Desenho fatorial 2×2 .

Config.	AF-TKD	Gating	Papel
Baseline Fixo	✗	✗	Referência — sem refinamento, sem supressão
Baseline+Gating	✗	✓	Controle negativo — supressão sem refinamento
AF-TKD Fixo	✓	✗	Refinamento temporal isolado
AF-TKD+Gating	✓	✓	Framework completo

Table 6: Delta de Cliff e Wilcoxon pareado ($n=4$), Baseline versus AF-TKD fixo.

Métrica	$\delta_{\text{Cliff}} \uparrow$	Magnitude	p
ECE	+1,000	Grande	0,0625
F1	+1,000	Grande	0,0625
FR	+0,250	Pequeno	0,2500
TTD _{ef}	+0,250	Pequeno	0,2500

$n=4$: menor p atingível = 0,0625. Magnitudes por Romano et al. [19]. Efeito pequeno em FR reflete sementes 44–45 com FR=0 já no Baseline.

4.3. Estudo de Ablação Fatorial 2×2

O fatorial 2×2 (Tabela 5) isola cada passo da hipótese mecânica. O Baseline Fixo estabelece a referência sem refinamento. O Baseline+Gating isola a supressão sobre resposta temporal não ajustada (controle negativo). O AF-TKD Fixo avalia o refinamento isolado. O AF-TKD+Gating verifica a hipótese completa.

Elo 1 — AF-TKD melhora antecipação temporal e cobertura. O Baseline sem refinamento apresenta $F1=0,862 \pm 0,015$, $FR=0,067 \pm 0,084$ e $TTD_{\text{ef}}=0,674 \pm 0,845$ s. Em episódios abruptos, FR atinge $0,115 \pm 0,145$, indicando que o modelo não acessa sinais precursores antes da manifestação plena do risco.

O AF-TKD reduz FR de 0,067 para $0,033 \pm 0,061$ (−51%) e TTD_{ef} de 0,674 para $0,333 \pm 0,612$ s (−51%), com F1 elevado para $0,893 \pm 0,030$. Nos episódios progressivos, a antecipação pré-onset sobe substancialmente (Tabela 7), evidenciando transferência de informação precursora pelo professor bidirecional. O efeito em F1 e ECE é de magnitude grande pelo delta de Cliff ($\delta=1,000$; Tabela 6); em FR e TTD_{ef} o efeito é menor ($\delta=0,250$), refletindo sementes 44 e 45 que já atingem FR=0 no Baseline fixo.

A Figura 2 documenta esse comportamento em escala de quadro; a Figura 3 apresenta a mudança na estrutura de incerteza.

Elo 2 — Incerteza estruturada viabiliza gating seletivo. A Figura 3(b) mostra a consequência direta do refinamento: no AF-TKD, H_t estratifica-se por fase de condução, separando períodos estáveis ($\bar{H}=0,37$ nats) de janelas pós-onset ($\bar{H}=0,63$ nats). No Baseline, ambas as fases produzem distribuições sobrepostas em 0,22 e 0,42 nats, sem separação operacionalmente útil. Com incerteza estruturada, o MHEG pode suprimir frames de baixa entropia (estado estável) e preservar atualizações nos frames de alta entropia, sem ajuste manual de janelas.

Elo 3 — Gating calibrado preserva cobertura. O Baseline+Gating confirma o controle negativo: FR sobe de 0,067 para $0,083 \pm 0,083$ com $62,2 \pm 11,9\%$ de supressão, piorando a cobertura




Figure 3: Estrutura de incerteza por fase de condução (semente 42, configurações `_fixed`). **(a)** Baseline: distribuições de H_t das quatro fases colapsam em faixa estreita, tornando H_t pouco informativo para distinguir quadros estáveis de quadros de risco. **(b)** AF-TKD: fases estratificam-se ao longo da faixa de entropia; Pós-onset satura próximo a $\ln 2$. **(c)** Diagrama de confiabilidade em nível de quadro (p_t vs. alvo contínuo y_{frame}): o AF-TKD mantém-se mais próximo da diagonal ($\text{ECE}_{\text{frame}}=0,044$ vs. $0,129$ do Baseline), indicando resposta temporal mais calibrada ao risco instantâneo. O ECE de episódio reportado na Tabela 7 usa métrica distinta (agregação por episódio).

em vez de melhorá-la. Sem incerteza estruturada, o MHEG não dispõe de sinal para decidir o que suprimir e tende a atuar justamente nos instantes de maior relevância.

O AF-TKD+Gating, com supressão similar ($62,1 \pm 12,6\%$) mas condicionada à incerteza ajustada, mantém $\text{FR}=0,000 \pm 0,000$ e $\text{F1}=0,907 \pm 0,044$, com TTD_{ef} de $0,002 \pm 0,001$ s. A Figura 4 exibe o perfil temporal de H_t , mostrando que no AF-TKD a incerteza se eleva consistentemente a partir de t_0 , enquanto no Baseline permanece uniformemente baixa.

Elo 4 — Gating seguro viabiliza inferência eficiente. O custo cai de $1,359 \pm 0,190$ ms (Baseline) para $0,156 \pm 0,055$ ms no AF-TKD+Gating ($-88,5\%$). A latência bruta do aluno LSTM permanece $\approx 0,41$ ms; o ganho decorre inteiramente das $62,1\%$ de supressões. Como o gating não altera a arquitetura de inferência, a latência nos instantes processados é determinística — requisito operacional crítico em sistemas embarcados. A $0,156 \text{ ms/q}^1$, o sistema atinge ≈ 6.400 FPS teóricos, com margem de $640\times$ acima do limiar de tempo real (100 ms a 10 Hz) e footprint de ≈ 98 KB (FP32), compatível com Jetson Nano e Qualcomm SA8155P sem quantização adicional.

A Tabela 7 consolida os resultados. Apenas o AF-TKD+Gating satisfaz simultaneamente os três objetivos.

4.4. Análise por Regime de Emergência

Os resultados agregados encobrem assimetria estrutural entre regimes (Tabela 8).

Regime progressivo. No Baseline, FR progressivo é $0,035 \pm 0,049$ com antecipação pré-onset de $0,069 \pm 0,040$ s. O AF-TKD elimina as falhas progressivas ($\text{FR}=0$) e eleva substancialmente a antecipação; a baixa variância inter-sementes ($\pm 0,164$ s) indica ganho estrutural.

Regime abrupto. O Baseline falha em $0,115 \pm 0,145$ dos episódios abruptos, com as falhas concentradas nas sementes 42 e 43. O AF-TKD reduz a falha de $0,115$ para $0,083 \pm 0,145$ nesse regime; a semente 43 concentra a maior taxa residual. O framework completo mantém $\text{FR}=0$ em ambos os regimes (sementes 42 e 45), indicando que a supressão calibrada não introduz degradação diferencial. Episódios abruptos permanecem o principal regime de dificuldade para o sistema.

4.5. Impacto da Bidirecionalidade

A hipótese testada é que a vantagem do professor reside no acesso bidirecional ao contexto temporal, não em escala paramétrica.

Eixo A — bidirecionalidade versus capacidade. Transformer e BiLSTM reduzem ECE em relação ao Baseline ($0,477$): Transformer alcança $0,330 \pm 0,014$; BiLSTM atinge $0,344 \pm 0,022$. A diferença emerge na antecipação: BiLSTM produz TTD_{θ} de $1,202 \pm 0,164$ s com variância $2,6\times$ menor que o Transformer ($0,948 \pm 0,432$ s), indicando que codificação bidirecional transfere padrões precursores mais consistentes. O maior FR do AF-TKD na política fixa ($0,033$ vs $0,004$ do TransKD) é resolvido pelo gating, que elimina a falha residual mantendo o ganho de antecipação.

Eixo B — implantabilidade do aluno. O aluno Transformer atinge $\text{F1}=1,000$ e $\text{FR}=0,000$, mas com custo de $2,358 \pm 1,905$ ms/q — $5,7\times$ acima do LSTM. Esse custo excede o orçamento embarcado por quatro razões: (i) latência de $2,4$ ms com margem insuficiente para módulos paralelos (ii) footprint $\approx 84\times$ maior ($\sim 8,2\text{M}$ vs ~ 98 KB), excedendo a SRAM de MCUs típicos; (iii) desvio de $\pm 1,9$ ms compromete o determinismo de tempo real; (iv) orçamento térmico de plataformas como Jetson Nano (~ 10 W) não suporta execução sustentada. O LSTM causal preserva todos

¹Resultado sobre sementes 42 e 45.




Figure 4: Perfil de H_t sobre 120 episódios críticos (semente 42). Painéis (a)–(b): mapa de calor para Baseline+Gating e AF-TKD+Gating. Painel (c): $\bar{H}_t \pm \frac{1}{2}\sigma$ relativo a $\Delta t = t - t_0$. No Baseline, H_t exibe queda pós- t_0 (linha vermelha tracejada); no AF-TKD, H_t cresce monotonicamente (linha azul), provendo sinal contínuo para o gating.

Table 7: Resultados do fatorial 2x2 em *streaming* causal (média $\pm$ desvio, 4 sementes, exceto † 2 sementes).

Modelo	Gating	F1 $\uparrow$	ECE $\downarrow$	FR $\downarrow$	TTD $_{\theta}$ (s) $\uparrow$	TTD $_b$ (s) $\downarrow$	TTD $_{ef}$ (s) $\downarrow$	ms/q $\downarrow$	%Sup $\uparrow$
LSTM-Baseline	Não	0,862 $\pm$ 0,015	0,477 $\pm$ 0,010	0,067 $\pm$ 0,084	0,069 $\pm$ 0,040	0,008 $\pm$ 0,005	0,674 $\pm$ 0,845	1,359 $\pm$ 0,190	0,0
LSTM-Baseline	Sim	0,862 $\pm$ 0,019	0,443 $\pm$ 0,025	0,083 $\pm$ 0,083	0,071 $\pm$ 0,013	—	0,846 $\pm$ 0,836	0,492 $\pm$ 0,176	62,2 $\pm$ 11,9
LSTM-AF-TKD	Não	0,893 $\pm$ 0,030	0,344 $\pm$ 0,022	0,033 $\pm$ 0,061	1,202 $\pm$ 0,164	0,000 $\pm$ 0,000	0,333 $\pm$ 0,612	0,816 $\pm$ 0,808	0,0
	Sim†	0,907 $\pm$ 0,044	0,306 $\pm$ 0,014	0,000 $\pm$ 0,000	0,583 $\pm$ 0,004	0,002 $\pm$ 0,001	0,002 $\pm$ 0,001	0,156 $\pm$ 0,055	62,1 $\pm$ 12,6

† 2 sementes (42, 45). TTD $_{\theta}$: antecipação pré-onset por derivada, episódios progressivos. TTD $_b$: somente episódios detectados. ECE: indicador auxiliar de qualidade de resposta temporal.

Table 8: Desempenho por regime (4 sementes para Baseline e AF-TKD Fixo; 2 sementes para AF-TKD+Gating).

Configuração	Progressivo (60%)		Abrupto (40%)		Global	
	FR	TTD $_{\theta}$ (s)	FR	TTD $_b$ (s)	FR	TTD $_{ef}$ (s)
LSTM-Baseline	0,035 $\pm$ 0,049	0,069 $\pm$ 0,040	0,115 $\pm$ 0,145	0,019 $\pm$ 0,013	0,067 $\pm$ 0,084	0,674 $\pm$ 0,845
AF-TKD Fixo	0,000	1,202 $\pm$ 0,164	0,083 $\pm$ 0,145	0,000 $\pm$ 0,000	0,033 $\pm$ 0,061	0,333 $\pm$ 0,612
AF-TKD+Gating †	0,000	0,853 $\pm$ 0,098	0,000	0,004 $\pm$ 0,002	0,000 $\pm$ 0,000	0,002 $\pm$ 0,001

† 2 sementes (42, 45).

esses requisitos ao mesmo tempo que, com AF-TKD, iguala ou supera o Transformer em cobertura.

4.6. Representação Contínua de Risco

O modelo é treinado com rótulos binários, mas p_t é contínuo. A Tabela 10 avalia se essa continuidade reflete estrutura semântica coerente com a escala de severidade, em episódios com receitas não vistas durante o treinamento (Tabela 4).

A escala aprendida é consistente com a hierarquia de risco: Normal produz $\bar{p}_{\max}=0,094 \pm 0,046$; Atenção, $0,355 \pm 0,036$; Alerta, $0,431 \pm 0,061$; e Crítico, $0,527 \pm 0,065$ — gradação monotônica que emerge sem supervisão sobre os níveis intermediários. Embora 30% dos episódios Normais apresentem

ao menos um instante com $p_t \geq \theta$, nenhum satisfaz o critério estável ($m=3$ consecutivos), confirmando taxa de falso positivo operacional nula.

4.7. Sensibilidade, Robustez e Viabilidade de Implantação

Multi-semente. A semente 43 apresenta FR=0,125 no AF-TKD Fixo, acima do orçamento de cobertura: essa partição concentra padrões abruptos com janela de antecipação inferior a 0,3 s, onde a ponderação exponencial não concentra gradiente suficiente antes de t_0 . O AF-TKD+Gating (sementes 42 e 45) elimina essa falha, com o MHEG atuando como regularizador nos instantes de maior ambiguidade. Ampliar para sementes 43 e 44 é a extensão imediata mais relevante.

Table 9: Ablação do professor (média $\pm$ desvio, 4 sementes). **Eixo A:** professor varia, aluno = LSTM causal. **Eixo B:** aluno varia, professor = BiLSTM.

Professor	Aluno	F1 $\uparrow$	ECE $\downarrow$	FR $\downarrow$	TTD θ (s) $\uparrow$	ms/q $\downarrow$
<i>Eixo A</i>						
— (Baseline)	LSTM	0,862 $\pm$ 0,015	0,477 $\pm$ 0,010	0,067 $\pm$ 0,084	0,069 $\pm$ 0,040	1,359 $\pm$ 0,190
Transformer	LSTM	0,883 $\pm$ 0,010	0,330 $\pm$ 0,014	0,004 $\pm$ 0,005	0,948 $\pm$ 0,432	0,705 $\pm$ 0,578
BiLSTM (AF-TKD)	LSTM	0,893 $\pm$ 0,030	0,344 $\pm$ 0,022	0,033 $\pm$ 0,061	1,202 $\pm$ 0,164	0,816 $\pm$ 0,808
<i>Eixo B</i>						
BiLSTM	LSTM (adotado)	0,893 $\pm$ 0,030	0,344 $\pm$ 0,022	0,033 $\pm$ 0,061	1,202 $\pm$ 0,164	0,816 $\pm$ 0,808
BiLSTM	Transformer	1,000 $\pm$ 0,000	0,472 $\pm$ 0,021	0,000 $\pm$ 0,000	0,164 $\pm$ 0,062	2,358 $\pm$ 1,905

Linha destacada = configuração adotada. Transformer-aluno fora do orçamento de implantação (§4.5).




Figure 5: Distribuições de $\bar{p}_{\max}$ por nível de risco em episódios borderline (semente 42). No Baseline, distribuições de Atenção e Alerta apresentam alta sobreposição. No AF-TKD, separação consistente entre os quatro níveis (Normal < Atenção < Alerta < Crítico).

Table 10: Representação contínua de risco (semente 42, $\theta=0,10$, $m=3$).

Nível	Comportamento	$\bar{p}_{\max}$	Frac. $\geq \theta^*$
Normal	Basal / sem distração	0,094 $\pm$ 0,046	30%
Atenção	Contexto adverso sustentado	0,355 $\pm$ 0,036	100%
Alerta	Distração breve	0,431 $\pm$ 0,061	100%
Crítico	Evento crítico	0,527 $\pm$ 0,065	$\approx 100\%$

*Ao menos um instante $p_t \geq \theta$. Nenhum episódio Normal atinge o critério estável ($m=3$).

Table 11: Sensibilidade a α (AF-TKD sem gating, semente 42).

α	F1 $\uparrow$	FR $\downarrow$	ECE $\downarrow$	TTD θ (s) $\uparrow$
0,05	$\approx 0,88$	$\approx 0,05$	$\approx 0,53$	$\approx 0,40$
0,15	0,876	0,000	0,324	1,155
0,30	$\approx 0,90$	$\approx 0,008$	$\approx 0,54$	$\approx 0,60$
0,50	$\approx 0,89$	$\approx 0,010$	$\approx 0,56$	$\approx 0,55$

Sensibilidade ao parâmetro α . O valor $\alpha=0,15$ oferece o melhor equilíbrio: valores menores diluem o foco sobre precursores;

valores maiores introduzem sensibilidade excessiva aos instantes imediatamente anteriores ao onset.

Robustez sensorial e viabilidade de implantação. Avaliações com ruído gaussiano sobre x_t ($\sigma \leq 0,10$) indicam cobertura estável. A $0,156 \pm 0,055$ ms/q com footprint de $\approx 1,4$ M parâmetros, o sistema é compatível com execução paralela de módulos complementares em Jetson Nano e Qualcomm SA8155P sem quantização adicional, dentro do orçamento de 100 ms a 10 Hz.

Custo energético e footprint de memória. O aluno LSTM possui ≈ 25 K parâmetros, resultando em footprint de ≈ 98 KB em precisão FP32 e ≈ 24 KB com quantização INT8 — compatível com memória estática de microcontroladores automotivos de entrada. A Tabela 12 consolida os indicadores de viabilidade para as três configurações principais.

A energia por instante é estimada pelo produto $E = P_{\text{sys}} \times t_{\text{lat}}^{(\text{JN})}$, onde $P_{\text{sys}}=5$ W é a potência do Jetson Nano no modo conservador e $t_{\text{lat}}^{(\text{JN})}$ é a latência estimada assumindo desaceleração




Figure 6: Desempenho por semente e IC 95% ($n=4$; AF-TKD+Gating $n=2$). Linha tracejada em $FR=0,05$: limite de cobertura. Apenas AF-TKD+Gating opera abaixo dessa linha em todas as sementes avaliadas.




Figure 7: Mapa de desempenho conjunto: FR versus ms/q com IC 95%. Região sombreada: $FR > 0,05$ (cobertura insatisfatória). Apenas AF-TKD+Gating satisfaz $FR=0$ e baixo custo simultaneamente, evidenciando que a resolução do *trade-off* requer ambos os componentes.

$\rho=10\times$ em relação à GPU de referência, razão consistente com a diferença de largura de banda de memória entre as plataformas (128 vs 25,6 GB/s). O gating reduz o número de inferências efetivas de $T=96$ para ≈ 36 por episódio (62,1% de supressão), produzindo redução de energia proporcional ao *skip rate* sem alteração da arquitetura de inferência.

Síntese experimental. O AF-TKD reduz FR de 0,067 para 0,000 e TTD_{ef} de 0,674 para 0,002 s, enquanto o gating reduz o custo em 88,5% sem penalidade de cobertura. O framework completo atinge $FR=0$, $F1=0,907$ e 0,156 ms/q dentro das restrições de *streaming* causal estrito, satisfazendo os três objetivos simultaneamente.

Table 12: Indicadores de viabilidade de implantação. Latência medida em GPU NVIDIA RTX 3050 Ti (PyTorch 2.0, $batch=1$, média das sementes 42–45). Latência estimada no Jetson Nano com $\rho=10\times$ (razão de largura de banda de memória). Energia estimada por $E=P_{sys} \times t_{lat}^{(JN)}$, $P_{sys}=5$ W.

Indicador	Baseline	AF-TKD	AF-TKD+Gating
Parâmetros	≈ 25 K (mesmo modelo)		
Footprint FP32/INT8	≈ 98 KB / ≈ 24 KB		
FLOPs/instante	≈ 28 KFLOPs		
Latência (RTX 3050 Ti)	1,359 ms	0,410 ms	0,156 ms
Latência est. (Jetson Nano)	$\approx 13,6$ ms	$\approx 4,1$ ms	$\approx 1,6$ ms
Energia/episódio est. [†]	6,52 J	1,97 J	0,75 J
Redução energética [‡]	n.a.	n.a.	88,5%
Skip rate	0%	0%	62,1%
Throughput (RTX)	736 FPS	2,439 FPS	6,410 FPS
Margem tempo real [§]	74 $\times$	244 $\times$	641$\times$

[†] Jetson Nano, modo 5 W, $\rho=10\times$; 96 instantes/episódio. Não inclui memória externa nem periféricos. INT8 reduz adicionalmente em $\approx 4\times$. [‡] Relativa ao Baseline, devida exclusivamente ao *gating*; Baseline e AF-TKD compartilham a mesma arquitetura de inferência. [§] $\Delta t_{max}=100$ ms (10 Hz).

4.8. Análise de Falhas Remanescentes

Os episódios com falha residual no AF-TKD Fixo ($FR=0,033$; $FR=0,125$ na semente 43) concentram-se no subconjunto abrupto com janela de antecipação inferior a 0,3 s, onde a ponderação exponencial não concentra gradiente informativo suficiente antes de t_0 . Nas sementes 42 e 45, a ativação do MHEG converte essas falhas em detecções bem-sucedidas, sugerindo que a supressão seletiva funciona também como regularizador temporal em episódios de alta ambiguidade.

A semente 43 concentra padrões abruptos com interações multimodais simultâneas não representadas nas demais partições. O *gap* sim-to-real permanece a limitação mais relevante para implantação: episódios sintéticos não capturam integralmente a variabilidade de ruído sensorial e a distribuição de receitas de datasets naturalísticos como DMD e AUC Distracted Driver.

5. Discussão

O resultado mais revelador do estudo de ablação não é o desempenho do *framework* completo em si, mas a trajetória que leva a ele. A configuração Baseline+Gating mostrou que suprimir instantes de processamento sem refinamento temporal não é uma escolha neutra, pois a taxa de falha aumenta porque o modelo não distingue, pela resposta de incerteza, entre instantes genuinamente redundantes e instantes onde o risco está emergindo.

Esse padrão é consistente com uma limitação implícita de abordagens de inferência adaptativa baseadas em confiança preditiva [20, 21, 22], que pressupõem que a confiança do modelo é intrinsecamente informativa sobre o estado do sistema, sendo que os presentes resultados sugerem que essa propriedade se torna operacionalmente útil apenas quando a resposta temporal é explicitamente otimizada durante o treinamento. O objetivo do *framework* não é maximizar acurácia preditiva isolada, mas preservar a cobertura temporal sob restrições agressivas de processamento contínuo, e essa distinção é tornada quantitativamente verificável pelo fatorial 2×2 .

Essa verificação depende de condições que os datasets naturalísticos disponíveis tipicamente não fornecem de maneira sistemática, como anotação determinística do instante de início do evento e penalização explícita de episódios não detectados na métrica principal. O TERA-Gen provê ambas, ancorado em *odds ratios* do SHRP2 para que os gradientes de risco reflitam evidências epidemiológicas sobre comportamentos ao volante. A estrutura multimodal dos episódios é particularmente relevante para a emergência de risco progressivo, onde a evidência precursora está distribuída por sinais comportamentais, contextuais e cinemáticos antes de produzir evidências suficientemente fortes em qualquer modalidade isolada.

O protocolo AF-TKD não é restrito à arquitetura específica utilizada neste trabalho. A ablação do professor é consistente com a interpretação de que a propriedade transferida é o acesso ao contexto futuro, de modo que substituir o BiLSTM por um professor com acesso sequencial equivalente ao do aluno reduz os ganhos de antecipação, enquanto a codificação bidirecional os preserva. Essa separação entre a informação temporal transferida e a implementação específica sugere que o princípio pode ser aplicado a outros pares professor-aluno em cenários de detecção temporal com anotação de onset disponível.

Três limitações circunscrevem o escopo. A principal é o *gap* sim-to-real, pois episódios sintéticos não capturam integralmente a variabilidade comportamental humana nem as condições de ruído de implantações reais; validação em bases como DMD e AUC Distracted Driver é o passo imediato mais necessário. A segunda é a robustez à ausência parcial de modalidades, relevante para frotas com sensoriamento heterogêneo. Por fim, a validação em plataformas embarcadas reais, considerando variação de *clock* e perfil energético completo, constitui etapa necessária antes de implantação em escala.

Em conjunto, os resultados sugerem que supervisão temporal orientada ao instante de início permite compatibilizar inferência adaptativa eficiente com cobertura temporal robusta em cenários de *streaming* causal estrito. Mais do que uma combinação es-

pecífica de arquitetura e hiperparâmetros, os resultados apontam para um princípio de projeto no qual o refinamento temporal é condição operacional para supressão seletiva segura. Sem essa condição, eficiência computacional e cobertura de detecção são objetivos em tensão; estabelecida, tornam-se complementares. Esse princípio é diretamente relevante para sistemas Edge AI sensíveis à latência nos quais o orçamento de processamento não admite execução integral a cada instante, e onde a manutenção de cobertura temporal sob supressão agressiva constitui o critério de projeto dominante.

6. Conclusão

A pergunta central deste trabalho era se é possível construir um sistema de detecção de risco temporal leve o suficiente para operar continuamente em hardware embarcado sem sacrificar a cobertura dos eventos críticos. A evidência experimental indica que sim, com uma condição verificada nos experimentos realizados: o modelo base deve possuir resposta temporal ajustada para que a incerteza preditiva reflita a proximidade do risco. Esse requisito não é satisfeito por treinamento convencional; sua violação, ilustrada pela configuração Baseline+Gating, aumenta sistematicamente a taxa de falha. O *framework* proposto, ao combinar destilação onset-aware com supressão adaptativa, satisfaz essa condição: cobertura integral dos episódios críticos nos experimentos realizados, $F1=0,907$ e redução de custo de 88,5% dentro das restrições de *streaming* causal estrito.

O mecanismo AF-TKD induz, como consequência observável do refinamento temporal, uma representação contínua de risco coerente com a hierarquia epidemiológica do SHRP2: o *framework* produz estimativas graduadas de severidade sem supervisão explícita sobre categorias intermediárias, tornando-o compatível com sistemas de alerta proporcional em ITS. O TERA-Gen complementa esse resultado ao fornecer anotação determinística de início de evento e métricas que penalizam explicitamente episódios não detectados, viabilizando a verificação quantitativa da hipótese proposta.

As extensões mais diretas concentram-se em fechar o *gap* sim-to-real: validação em datasets naturalísticos com anotação de início de evento, avaliação de robustez à ausência parcial de modalidades para frotas heterogêneas, e validação em hardware embarcado com perfil energético completo.

A evidência experimental indica que detecção temporal eficiente e cobertura robusta não são objetivos mutuamente exclusivos em sistemas embarcados, desde que a inferência adaptativa seja sustentada por refinamento temporal explicitamente otimizado durante o treinamento. Nessas condições, modelos causais leves tornam-se capazes de antecipar eventos críticos mesmo sob restrições estritas de *streaming* sem acesso a contexto futuro, preservando cobertura temporal sob supressão agressiva de processamento. Esses resultados sugerem que refinamento temporal orientado ao onset pode transformar inferência adaptativa de um mecanismo heurístico em uma estratégia operacionalmente viável para sistemas Edge AI sensíveis à latência e a restrições de processamento contínuo.

Declaração de contribuição dos autores (CRediT)

Ângela Brígida Albarello: Conceitualização, Metodologia, Software, Análise formal, Investigação, Redação — rascunho original, Redação — revisão e edição. **Edna Dias Canedo:** Supervisão, Conceitualização, Redação — revisão e edição. **Vinícius P. Gonçalves:** Redação — revisão e edição. **Leandro A. Villas:** Supervisão, Redação — revisão e edição. **Rodolfo I. Meneguette:** Redação — revisão e edição. **Geraldo P. Rocha Filho:** Supervisão, Redação — revisão e edição.

Declaração de conflito de interesses

Os autores declaram não possuir interesses financeiros concorrentes conhecidos nem relações pessoais que possam ter influenciado este trabalho.

Disponibilidade de dados

O código do TERA-Gen e os datasets sintéticos serão disponibilizados em repositório público após a aceitação do artigo.

Financiamento

Esta pesquisa não recebeu financiamento específico de agências de fomento.

Agradecimentos

Os autores agradecem à infraestrutura de computação da Universidade de Brasília pelo suporte às avaliações experimentais.

Declaração sobre o uso de IA generativa

Durante a preparação deste artigo, os autores utilizaram ferramentas de inteligência artificial generativa para assistência linguística e melhoria de legibilidade. Todo o conteúdo foi subsequentemente revisado e editado pelos autores, que assumem plena responsabilidade pela integridade do material publicado.

References

- [1] Y. Shi, K. Yang, T. Jiang, J. Zhang, K. B. Letaief, Communication-efficient edge ai: Algorithms and systems, *IEEE Communications Surveys & Tutorials* 22 (4) (2020) 2167–2191. doi:10.1109/COMST.2020.3007787.
- [2] K. Hariharan, S. Manikandan, R. Priyadharshini, Real-time driver monitoring systems on Edge AI devices, *arXiv preprint <https://arxiv.org/abs/2304.01555>* (2023).
- [3] S. Bouhsissin, N. Sael, F. Benabbou, Driver behavior classification: A systematic literature review, *IEEE Access* 11 (2023) 14128–14153.
- [4] M. Xu, Y. Xiong, H. Chen, X. Li, W. Xia, Z. Tu, S. Soatto, Long short-term transformer for online action detection, in: *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2021, pp. 22610–22622.
- [5] T. A. Dingus, F. Guo, S. Lee, J. F. Antin, M. Perez, M. Buchanan-King, J. Hankey, Driver crash risk factors and prevalence evaluation using naturalistic driving data, *Proc. Natl. Acad. Sci. U.S.A.* 113 (10) (2016) 2636–2641. doi:10.1073/pnas.1513271113.
- [6] V. Campos, B. Jou, X. Giró-i Nieto, Skip RNN: Learning to skip state updates in recurrent neural networks, in: *Int. Conf. Learn. Represent. (ICLR)*, 2018.
- [7] Z. Wu, C. Xiong, C.-Y. Ma, R. Socher, L. S. Davis, AdaFrame: Adaptive frame selection for fast video recognition, in: *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2019, pp. 1278–1287.
- [8] J. Fang, D. Yan, J. Qiao, J. Xue, H. Yu, Dada: Driver attention prediction in driving accident scenarios, *IEEE Transactions on Intelligent Transportation Systems* 23 (6) (2022) 4959–4971. doi:10.1109/TITS.2020.3044678.
- [9] E. Michelaraki, C. Katrakazas, S. Kaiser, T. Brijs, G. Yannis, Real-time monitoring of driver distraction: State-of-the-art and future insights, *Accid. Anal. Prev.* 192 (2023) 107241.
- [10] J. D. Ortega, N. Kose, P. Cañas, M.-A. Chao, A. Unnervik, M. Nieto, O. Otaegui, L. Salgado, Dmd: A large-scale multi-modal driver monitoring dataset for attention and alertness analysis, in: *Computer Vision – ECCV 2020 Workshops*, Vol. 12538 of *Lecture Notes in Computer Science*, Springer, 2020, pp. 387–405. doi:10.1007/978-3-030-66823-5_23. URL https://doi.org/10.1007/978-3-030-66823-5_23
- [11] Y. Zhao, P. Krähenbühl, Real-time online video detection with temporal smoothing transformers, in: *European Conference on Computer Vision (ECCV)*, Vol. 13694 of *Lecture Notes in Computer Science*, Springer, 2022. doi:10.1007/978-3-031-19830-4_28.
- [12] J. Wang, G. Chen, Y. Huang, L. Wang, T. Lu, Memory-and-anticipation transformer for online action understanding, in: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 13824–13835. doi:10.1109/ICCV51070.2023.01270.
- [13] G. Hinton, O. Vinyals, J. Dean, Distilling the knowledge in a neural network, *arXiv:1503.02531*. Presented at the NIPS 2014 Deep Learning Workshop (2015). arXiv:1503.02531. URL <https://arxiv.org/abs/1503.02531>
- [14] H. Zheng, D. Cao, J. Xu, R. Ai, W. Gu, Y. Yang, Y. Liang, Distilling temporal knowledge with masked

feature reconstruction for 3D object detection, preprint. arXiv:2401.01918 (2024). arXiv:2401.01918, doi: 10.48550/arXiv.2401.01918.

- [15] M. F. Bajestani, Y. Yang, TKD: Temporal knowledge distillation for active perception, in: Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV), 2020, pp. 2282–2291. doi:10.1109/WACV45572.2020.9093437.
- [16] A. Graves, Adaptive computation time for recurrent neural networks, in: Adv. Neural Inf. Process. Syst. (NeurIPS), 2016, pp. 1–10.
- [17] Z. Wu, C. Xiong, Y.-G. Jiang, L. S. Davis, LiteEval: A coarse-to-fine framework for resource efficient video recognition, in: Adv. Neural Inf. Process. Syst. (NeurIPS), 2019.
- [18] T. Fawcett, F. J. Provost, Activity monitoring: Noticing interesting changes in behavior, in: Proceedings of the Fifth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 1999, pp. 53–62. doi:10.1145/312129.312195.
- [19] J. Romano, J. D. Kromrey, J. Coraggio, J. Skowronek, Appropriate statistics for ordinal level data: Should we really be using t-test and cohen’s d for evaluating group differences on the nsse and other surveys?, in: Annual Meeting of the Florida Association of Institutional Research, Cocoa Beach, Florida, USA, 2006, paper presented at FAIR Conference.
- [20] S. Teerapittayanon, B. McDanel, H. T. Kung, Branchynet: Fast inference via early exiting from deep neural networks, in: Proceedings of the 23rd International Conference on Pattern Recognition (ICPR), 2016, pp. 2464–2469. doi:10.1109/ICPR.2016.7900006.
- [21] S. Laskaridis, A. Kouris, N. D. Lane, Adaptive inference through early-exit networks: Design, challenges and directions, Proceedings of the 5th International Workshop on Embedded and Mobile Deep Learning (2021).
- [22] Y. Kaya, S. Hong, T. Dumitras, Shallow-deep networks: Understanding and mitigating network overthinking, in: ICML, 2019.